Beyond Vision 簡報核對報告

11 頁投影片 `docs/Beyond Vision_presentation.pdf` 與專案 artifacts 的逐項比對：數字是否一致、結論是否被統計支持、標籤是否與系統相符。

嚴重度	數量	代表問題
高	4	C「勝過」A、clip=0.35 的 visual 結論、A 的 worst 誤標、B 的 upper bound
中	2	1,968 的語意、Sentiment / Intent 命名
低	7	頁數、模型數、unseen、grade-1 簡化、延遲並排、Reaction Suggestion、排版

一句話結論 主要表格的數字幾乎都與 artifacts 一致；需要修正的是**四處結論性措辭**：C 並非顯著勝過 A、clip = 0.35 沒有補上 visual 缺口、B 不是上界、1,968 不是資料集筆數。其餘為命名與簡化問題。

怎麼讀這份報告

- 第 2 節把所有發現壓成一頁表格，先看嚴重度與頁碼。
- 第 3–4 節逐項列出投影片原文、系統實際值、證據路徑與建議寫法；每一項都可以用右側的檔案與 JSON key 重現。
- 第 6 節列出已核對一致的內容，避免把整份簡報誤判為錯誤。

投影片	本報告
docs/Beyond Vision_presentation.pdf (11 頁)	beyond_vision_review.pdf (2026-11-11)
資料快照	**核對範圍**
2026-11-01T15:12:38+00:00	評估指標、資料量、ablation、API 與 UI、類別命名

本報告由 `docs/make_presentation_review_pdf.py` 讀取 repo artifacts 生成；未修改簡報、程式或設定。

1 核對方法與資料來源

所有「系統實際」都以 repo 內可重跑的 artifacts 為準，不採用文件中的二手數字。簡報頁碼指 PDF 的實際頁次。

Artifact	用途
`data/reports/compare.json`	策略指標、per-category mAP、latency、paired bootstrap、Holm、ablations
`data/manifest.meta.json`	6,382 annotations → 6,378 records、4 筆重複
`data/gallery.db`	split 計數；1,968 筆 literal metaphor 列
`data/eval/memecap_eval_v1.json`	240 題、80/80/80、類別名稱、來源 split
`configs/default.yaml`	B/C 權重、模型、index 型別、evaluation 門檻
`src/tsr/api.py` / `web/`	API endpoint 數、HTML 檔數

表 1. 核對所使用的檔案。

判讀原則：**數字正確**與**結論正確**分開看。簡報的表格數字幾乎全部吻合，但部分「勝過 / 最佳 / 上界」的句子超過了 artifacts 支持的範圍。

2 摘要：所有發現

編號	嚴重度	頁	發現	與系統的差異
F1	高	p.8	C「beats」pure CLIP	delta +0.0124，p_holm = 1.0，CI 跨 0；統計上不顯著
F2	高	p.8	clip weight 調到 0.35 可追上 CLIP	0.35 的 visual mAP = 0.2715，仍低於 CLIP 的 0.3153
F3	高	p.8	A 的 worst = 0.444；+9.5%	A 的 worst 是 visual 0.3153；0.444 是 intent；+9.5 是百分點
F4	高	pp.4/8	B 是 upper bound / oracle / ceiling	B without CLIP = 0.7802 > 0.7608；B 也未看 qrels
F5	中	p.4	1,968 noisy entries stripped	1,968 是 literal metaphor 列；資料集只少 4 筆重複
F6	中	pp.1/3/8	Sentiment 與 Intent 混用	系統類別是 intent（meme_captions），不是 sentiment
F7	低	多頁	六項措辭 / 簡化問題	見第 5 節，不影響主要數字

表 2. 依嚴重度排序；F1–F4 會影響評審對結果的解讀。

嚴重度定義

- **高**：句子會改變評審對結果的解讀，或把不顯著的差異寫成勝負；必須改。
- **中**：數字正確，但名詞或單位指向錯的東西（資料筆數、類別名稱）；會誤導但不影響主表。
- **低**：措辭、簡化、排版與單頁並排造成的誤讀；口頭報告前修掉即可。

未列入的細節（例如動畫順序、圖示選擇）不影響事實陳述，因此不在此報告。

3 高嚴重度：會改變結論的四項

高 F1.「C beats pure CLIP」在統計上不成立 投影片 p.8

投影片原文「Best Annotation-Free Model: C · VLM, mAP = 0.4519 — Beats pure CLIP (0.4395)」

系統實際 C 的 mAP 點估計為 0.4519，A 為 0.4395，delta = **+0.0124**。但 paired bootstrap 的 95% CI 是 **[-0.0382, 0.0641]**，跨過 0；p_raw = 0.640，**p_holm = 1.0**，`significant = false`。其餘四個指標（MRR、nDCG@10、P@1、R@10）也全部不顯著。專案報告的結論是 A 與 C 沒有可偵測的差異。

證據 `data/reports/compare.json` → `pairwise[clip, vlm].comparisons[mAP]`。Holm family = 3 組配對 × 5 指標 = 15 個檢定。

建議寫法「C 的 mAP 略高於 A（+0.012），但 paired bootstrap 顯示差異不顯著（95% CI 跨 0，p_holm = 1.0），兩者可視為同等。」

高 F2. pixel weight 調到 0.35 並沒有讓 C 在 visual 上追上 CLIP 投影片 p.8

投影片原文「Default Strategy C loses to pure CLIP (0.315) on literal visual queries **until pixel weight is raised to 0.35.**」

系統實際 在 `vlm + CLIP 0.35` 這個 ablation 中，C 的 visual mAP 是 **0.2715**，仍低於 A 的 **0.3153**。0.35 只把 C 的整體 mAP 從 0.4519 提高到 0.4720；「追上 CLIP」的因果與數值都不成立。

證據 `data/reports/compare.json` → `ablations['vlm + CLIP 0.35'].per_category.visual.mAP`；對照 `strategies.clip.per_category.visual.mAP`。

建議寫法「提高 pixel weight 會改善 C 的整體 mAP，但 visual 類別仍低於純 CLIP（0.2715 vs 0.3153），因此 C 的 visual 缺口不是單靠調權重就能補上。」

高 F3.「A 的 worst 0.444」與「+9.5%」的類別和單位都不對 投影片 p.8

投影片原文「on Intent queries, Strategy C jumps from **Strategy A's worst score of 0.444** up to 0.539 (**+9.5%**)」

系統實際 A 的三個類別是 visual **0.3153**、intent **0.4444**、metaphor 0.5588；**A 的最差是 visual，不是 0.444**。C 的 intent 為 0.5390，與 A 的差是 **9.5 個百分點**；若以相對增幅表示則是 **+21.3%**。原文把「百分點」寫成「百分比」，又把 A 的中段成績標成 worst。

證據 `data/reports/compare.json` → `strategies.{clip,vlm}.per_category.*.mAP`。

建議寫法「在 intent 類別，A 為 0.444、C 為 0.539，C 高出 9.5 個百分點（相對 +21.3%）；A 的最差類別其實是 visual（0.315）。」

高 F4. B 不是 upper bound / oracle，0.7608 也不是 ceiling 投影片 pp.4/8

投影片原文「B · CLIP + NLP — **Human-annotated upper bound**」；「Sets the performance ceiling ... Yes (**Oracle**)」

系統實際 B 的預設配置 mAP 是 0.7608，但同一份報告的 ablation 顯示 **B without CLIP pixels = 0.7802**（+0.0194），比預設更高；因此 0.7608 既不是 B 的最佳配置，也不是系統上界。B 只索引人類標註，並沒有讀取 qrels，不具備 oracle 的條件；它是 annotation-rich 的強基準（reference），不是 upper bound。

證據 `data/reports/compare.json` → `ablations['clip_nlp - CLIP']`；qrels 只存在於 `data/eval/*.qrels.jsonl`，策略端不讀取。

建議寫法「B 是人類標註豐富的參考基準（annotation-rich reference）；移除 CLIP 後 mAP 反而升到 0.7802，說明 0.7608 不是上限。」

4 中嚴重度：數字對，但語意放錯位置

中 F5.「1,968 noisy entries stripped」把 metaphor 列當成資料集筆數 投影片 p.4

投影片原文「MemeCap: 6,378 verified memes (5,820 trainval + 558 test) · **1,968 noisy entries stripped**」

系統實際 資料集本身是 **6,382 → 6,378**，只少了 **4 筆 SHA-1 重複**，沒有刪掉 1,968 張圖。**1,968** 是 `metaphors` 表中 meaning = `not related to the meme context` 的列數（總共 14,139 列），在建立 B/C 文件時被排除。它既不是圖片，也不是 meme 條目。

證據 `data/manifest.meta.json`；`data/gallery.db` → `select count(*) from metaphors where meaning='not related to the meme context'` = 1,968。

建議寫法「資料集去重後為 6,378 張（4 筆重複）；另有 1,968 筆 literal metaphor 列在建構文件時排除，不計入 B/C 的文字證據。」

中 F6. Sentiment 與 Intent 混用，且與系統類別名稱不一致 投影片 pp.1/3/8

投影片原文「Search by **Sentiment**: abstract emotion → reaction meme」；表頭「**Sentiment** (80)」；但 p.7 寫的是「80 **Intent**」

系統實際 系統與 `/evaluation` 頁使用的類別鍵是 **intent**，來源欄位是 `meme_captions`（intended meaning，也就是笑點/意圖），不是情緒正負的分類。Intent 與 sentiment 是不同概念；同一份 deck 內兩種叫法並存，會讓評審不清楚到底量的是哪一種。

證據 `data/eval/memecap_eval_v1.json` → `category` `{visual, intent, metaphor}`；`web/eval.js` 直接以類別鍵渲染表格，沒有改名為 Sentiment。

建議寫法 全份統一使用「Intent（intended meaning）」；若要在口頭表達「情緒型查詢」，可加一句說明，但不要把它當成類別名稱。

5 低嚴重度：措辭、簡化與排版

頁	投影片說法	實際情況
p.2	Dataset & 3 Models	3 條 strategies；模型元件有 4 個：CLIP、BGE-small、BGE-reranker、Qwen2.5-VL-3B
p.5	7 HTML/JS pages	服務 7 條 page routes，但只有 5 個 HTML 檔（search.html 重複使用）
p.7	558 unseen test memes	數量正確（240 題來自 240 張不同 test 圖）；但沒有訓練階段，B 也索引 test 圖的標註，「unseen」只是 split 說法，真正的保護是 leakage gate
p.7	Grade 1 = near-equivalent or shared rare metaphor	還要求共享 metaphor 的 meaning 相同、且 df □ 10；只共享常見標籤不算
p.8	B 226 ms（43 ms no-rerank）	43 ms 屬於沒有 reranker 的配置（mAP 0.6887），不是 0.7608 的延遲；並排容易讓人以為同一品質可以 43 ms 跑完
p.1	Search & Reaction Suggestion	系統只有檢索與詳情；repo 內沒有 reaction suggestion 的 endpoint 或 UI
p.4/9	「metaphors pair」、「BGE -reranker-base」	漏右括號；模型名稱連字號位置錯誤（BGE-reranker-base）

表 3. 不影響主要數字，但建議在口頭報告前修掉。

6 與系統一致的內容

為避免把整份簡報當成錯誤，以下逐項核對結果是**一致**的；簡報的主要數據表可以直接沿用。

項目	投影片	系統實際
資料量與 split	6,378（5,820 + 558）	6,378（5,820 + 558）
mAP：A / B / C	0.4395 / 0.7608 / 0.4519	0.4395 / 0.7608 / 0.4519
Visual mAP：A / B / C	0.315 / 0.631 / 0.247	0.3153 / 0.6313 / 0.2469
Intent mAP：A / B / C	0.444 / 0.739 / 0.539	0.4444 / 0.7389 / 0.5390
Metaphor mAP：A / B / C	0.559 / 0.912 / 0.570	0.5588 / 0.9121 / 0.5697
p50 latency：A / B / C	14 / 226 / 35 ms	14.36 / 225.55 / 35.25 ms
Ablation 位移	-0.0721 / +0.0194 / -0.0597	-0.0720 / +0.0194 / -0.0597
Query 數量與類別	240；80/80/80	240；80/80/80
Gates	8-gram、短文件、copy run <5、Jaccard <0.6	與 src/tsr/evaluate.py 的 check_leakage 一致
模型與維度	CLIP ViT-L-14 768-d；BGE 384-d	config 與 index meta 一致
Index / 後端	FAISS IndexFlatIP；FastAPI	index.type = flat；IndexFlatIP；FastAPI
API endpoints	18	18 個 @app.get/put 路由
VLM 覆蓋	6,378 descriptions	probe.vlm_captions = 6,378
B / C 權重	B 0.50/0.30/0.20；C 0.2 CLIP	configs/default.yaml 相同
VLM 六欄位	scene/OCR/meaning/ metaphors/emotions/keywords	encoders/vlm.py 的 prompt schema 相同

7 方法論備註：缺了顯著性，才會出現「beats」

簡報第 7–9 頁完整交代了 leakage gate 與 ablation，但**沒有提到 bootstrap CI 與 Holm–Bonferroni**；而專案的 evaluation 設計正是以這兩者為核心。少了這一層，點估計的排序就會被寫成「最好 / 勝過 / 上界」。

- A 與 C 的 mAP 差為 +0.0124，95% CI [-0.0382, 0.0641]，p_holm = 1.0；這在報告裡是「無顯著差異」，不是「C 勝」。
- B 對 A、B 對 C 的五個指標都顯著（p_holm = 0.015），這部分簡報的「B 最好」是站得住的；但「upper bound」仍是比「顯著較好」更強的宣稱。
- Bootstrap 解析度下限是 1/1000 = 0.001；報告中的 0.001 不應被解讀為精確的 p 值。

建議在口頭報告時補一句：「B 的優勢在 Holm 校正後仍顯著；A 與 C 的差異則落在雜訊範圍內。」這樣既保留 B 的結論，也不會讓 A/C 的比較被追問。

本報告只做核對，未修改簡報、程式或設定。所有數值可由 `python -m tsr compare` 與 `data/reports/compare.json` 重現。